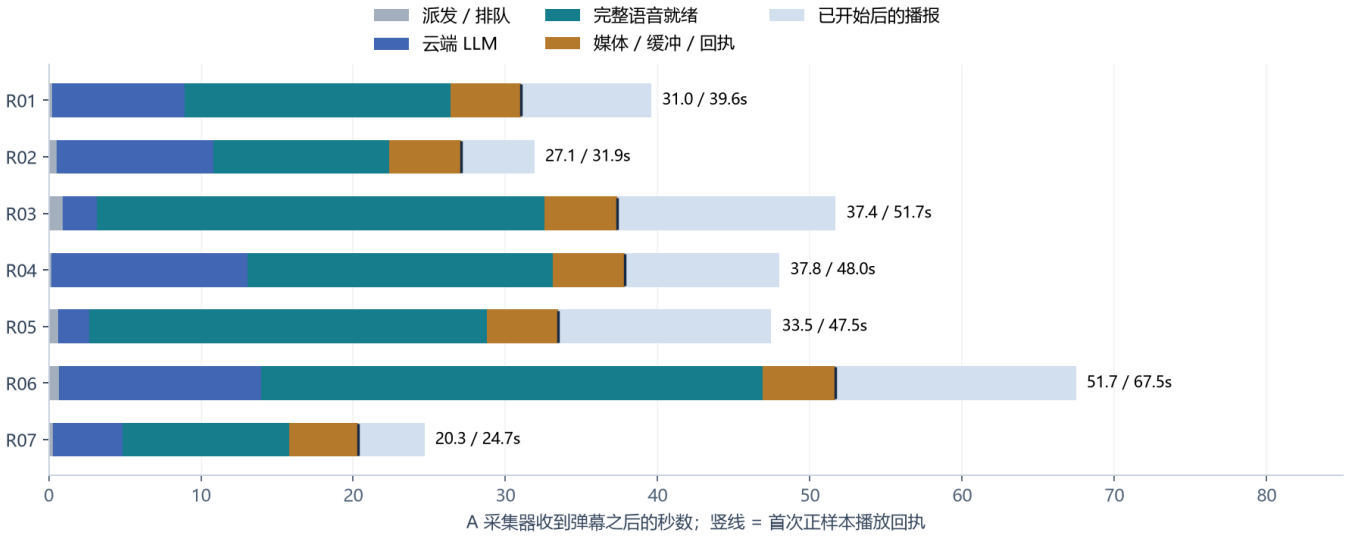
一句话，如何抵达直播间

A4090 负责人物与语音，B3080 负责接收与官方直播姬。复盘收到弹幕、云端对话、完整语音生成、媒体播放和下播记忆的每一个周期。



7 条真实弹幕	平均首次回执	平均完整完成	语音加权 RTF
7 / 7 完整播完	34.10 秒	44.40 秒	1.95

首播等待约 62.2% 来自完整语音准备。播放源稳定约 25 FPS，但当前语音服务需要先生成整段 WAV；两者对应不同性能问题。

下播后的状态：内部会话已结束，弹幕采集已停止，模型保持常驻。记忆维护仍 DEFERRED / budget，不能称为长期事实整理已完成。

截止官方直播姬正样本播放回执；不含平台 CDN 与观众端延迟。报告为冻结快照。

测量对象与口径

分组	样本	完成	首次均值/s	用途
本场真实弹幕	7	7	34.10	主性能结论
官方客户端验收	5	5	22.83	4 Echo + 1 Chat
较早调试	20	19	30.57	含异常，不混入主均值

当前 A 日期内留存 32 条记录：31 COMPLETED，1 UNKNOWN。完整逐条表见附录和 CSV；公开数据不包含对话正文或观众身份。

主要时间都取 A：平台采集 received_at、状态事件、A 收到 B 播放回执。同机时间相减可避免跨机器时钟差；平台 occurred_at 只作参考，曾与 A 出现 -212 ms 差值。

计时项	起点	终点
首次播放回执	A 采集器 received_at	首个 accepted 且 played_samples > 0 的回执
完整回复	A 采集器 received_at	playback.completed
LLM 阶段	request.thinking	utterance.text_ready
完整语音准备	utterance.text_ready	utterance.audio_ready
缓冲与回执	utterance.audio_ready	首个正样本回执
RTF	MOSS wall seconds	除以有效音频 seconds

首次回执不是扬声器物理起音时间。官方五段脚本墙钟值含轮询与跨设备计时，和 A 账本有差异；本报告的周期对比统一用 A。经验 P95 采用线性插值，7 条小样本仅用于描述。

当前双机职责

组件	A4090	B3080
硬件	48 GB GPU；约 64 GB RAM；80 逻辑 CPU	10 GB GPU；约 64 GB RAM；48 逻辑 CPU
模型	MOSS04 + MuseTalk FP16 batch8	不加载 TTS / 人物模型
对话状态	DSH / Humanity 连接层、SQLite 唯一写者	只转发、渲染和消费回执
媒体	720 x 1280 / 25 FPS；48 动作素材；NVENC	软件 H264 解码；Canvas / WebAudio
链路	共享 H264 + PCM -> 虚拟局域网	8020 轻量接收 -> 官方直播姬 -> 平台
声音	MOSS24k WAV -> 16k PCM	浏览器素材源内音频；桌面 / 麦克风静音

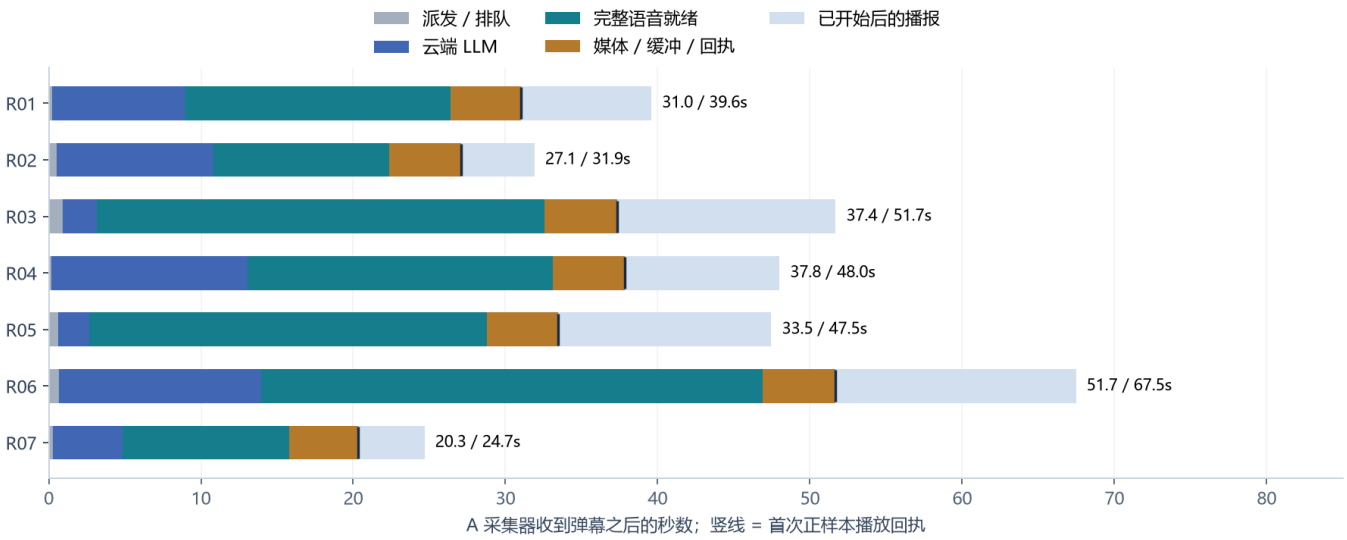
A：女A / 林知夏，日光宿舍，MOSS v04 明朗亲和。NF4 4-bit / BF16 compute，FP32 CPU codec。DSH 0.2.0-rc.2，Humanity 0.1.17，Node v24.22.1。native_humanity_tools=false；人格与记忆由项目连接层整合。

B 旧推理进程已经退休，415 个旧状态文件归档保留，未混入 A。先前本机接收器已关闭。身体动作使用预生成素材，口型与融合随当前语音推进，不是每次完整生成一个新身体视频。

MOSS 启动冷加载留存 70.970、62.823、60.795 秒；当前采用模型常驻，冷加载不计入每次回复。

首回执与整句结束分别统计

七条真实回复的完整周期

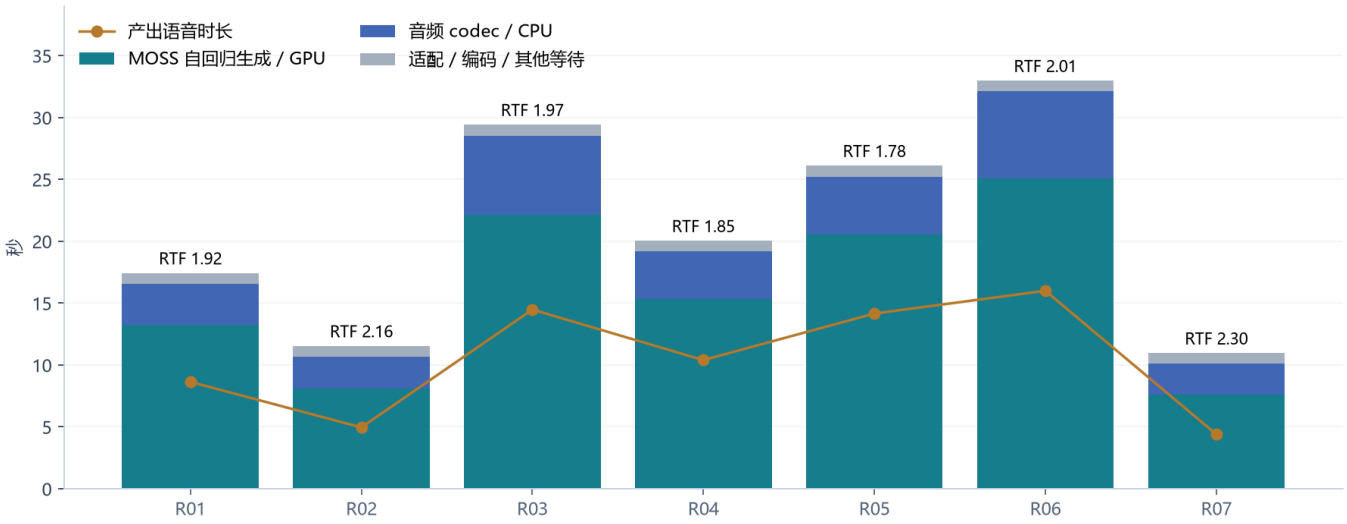


案例	字数	LLM	TTS	媒体	首播	完成
R01	36	8.75	17.43	4.64	31.02	39.59
R02	24	10.26	11.54	4.72	27.07	31.91
R03	73	2.22	29.42	4.78	37.35	51.70
R04	58	12.90	20.04	4.71	37.82	48.00
R05	69	2.05	26.10	4.70	33.46	47.46
R06	75	13.26	32.97	4.79	51.70	67.48
R07	19	4.57	10.96	4.51	20.32	24.68

单位：秒。首播平均 34.103，中位 33.457，最慢 51.695；完整平均 44.403，最慢 67.479。首次之前派发均值仅 0.485 秒，低流量场景没有显著排队积压。

一次只发一条，以样本平均周期估算约 1.35 条 / 分钟。队列容量只限制积压，不提高合成速度。该数字是规划估计，尚未经持续高流量压力测试。

语音为何生成得慢



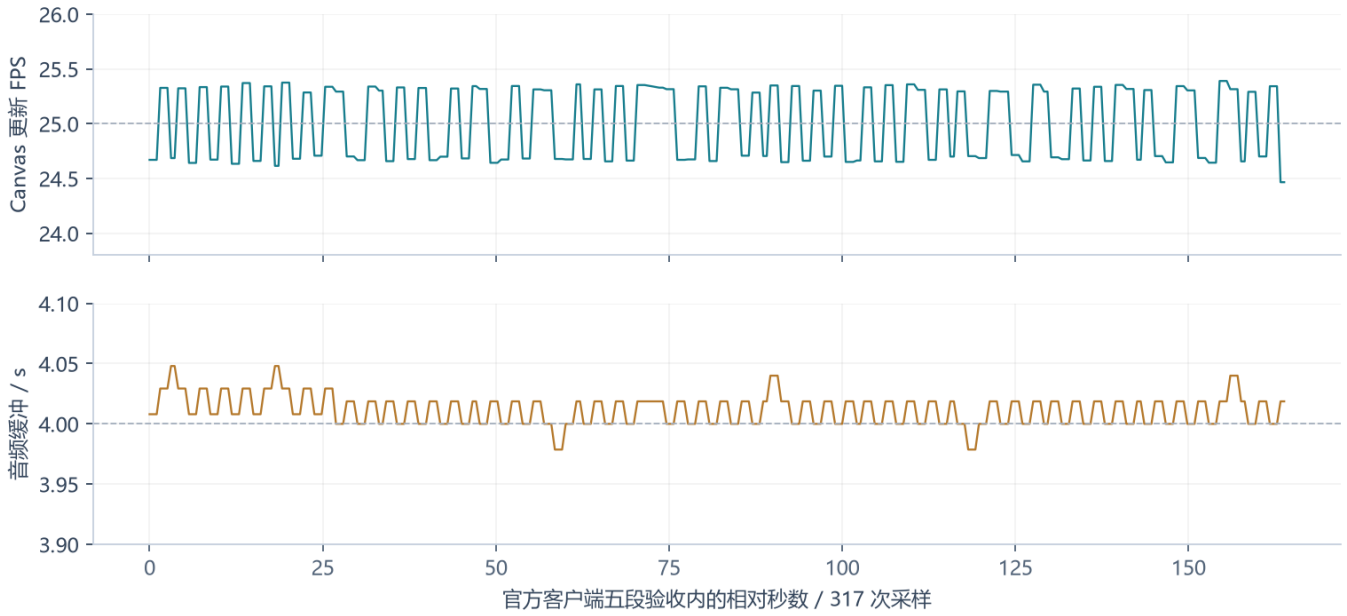
案例	音频/s	GPU生成	CPU codec	服务wall	RTF
R01	8.64	13.27	3.28	16.56	1.92
R02	4.96	8.09	2.61	10.71	2.16
R03	14.48	22.15	6.38	28.56	1.97
R04	10.40	15.36	3.82	19.20	1.85
R05	14.16	20.55	4.67	25.24	1.78
R06	16.00	25.09	7.04	32.15	2.01
R07	4.40	7.62	2.49	10.12	2.30

总音频 73.04 秒，服务 wall 142.547 秒；加权 RTF 1.9516。平均生成 16.019 秒、codec 4.328 秒；再加约 0.844 秒适配等准备，完整 TTS 为 21.208 秒。

70 字分段用于控制 KV-cache，并不提供流式播放：每段都完成后才拼接返回。R03、R06 是两段。MOSS 日志 UUID 与 DSH ID 不同，本报告按先后顺序关联，并校验全部 32 组字数与音频时长一致。

官方嵌入源的 317 次采样

接收与播放是否稳定

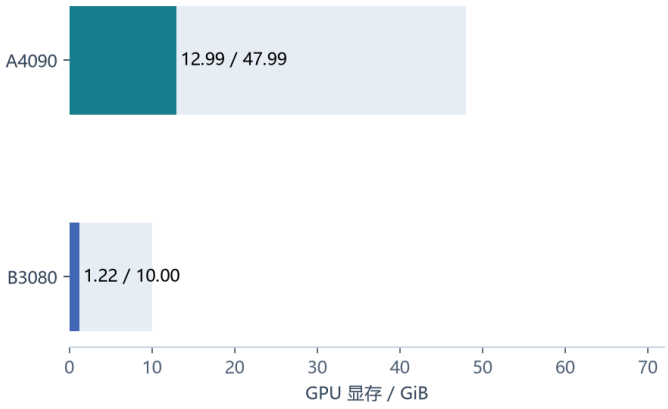


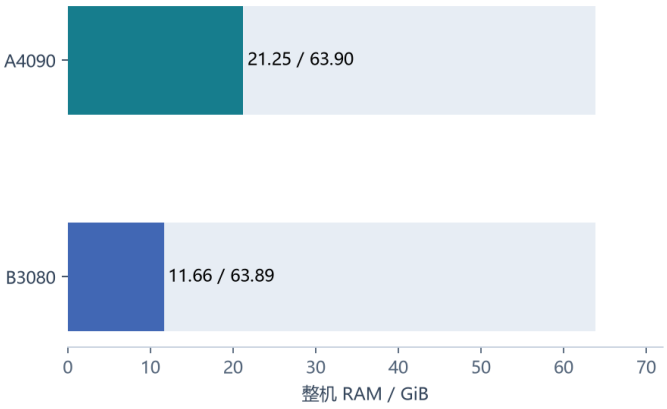
指标	五段窗口	延长观察，包含下播预览
Canvas FPS	中位 25.285，范围 24.466 - 25.390	末值约 25.34
欠载 / 缺包 / 解码错 / 跳帧	全部 0	全部 0
最大媒体到达间隔	91.8 ms	551.5 ms
缓冲	均值 4.011 s	末值 3.629 s
观察范围	163.819 s，5 条用例	媒体时钟累计 114.40 min

同一接收器仅 1 次上游 WebSocket，0 上游错误。累计网关媒体约 2.797 GB，按媒体时钟粗算 3.260 Mbps；不是公开推流码率，未含全部线缆开销。

Canvas 更新 FPS 不能代替显示器实际呈现帧率、口型模型吞吐或观众画质。预览持续稳定也不能证明房间仍在公开直播。

显存、内存与整卡功耗





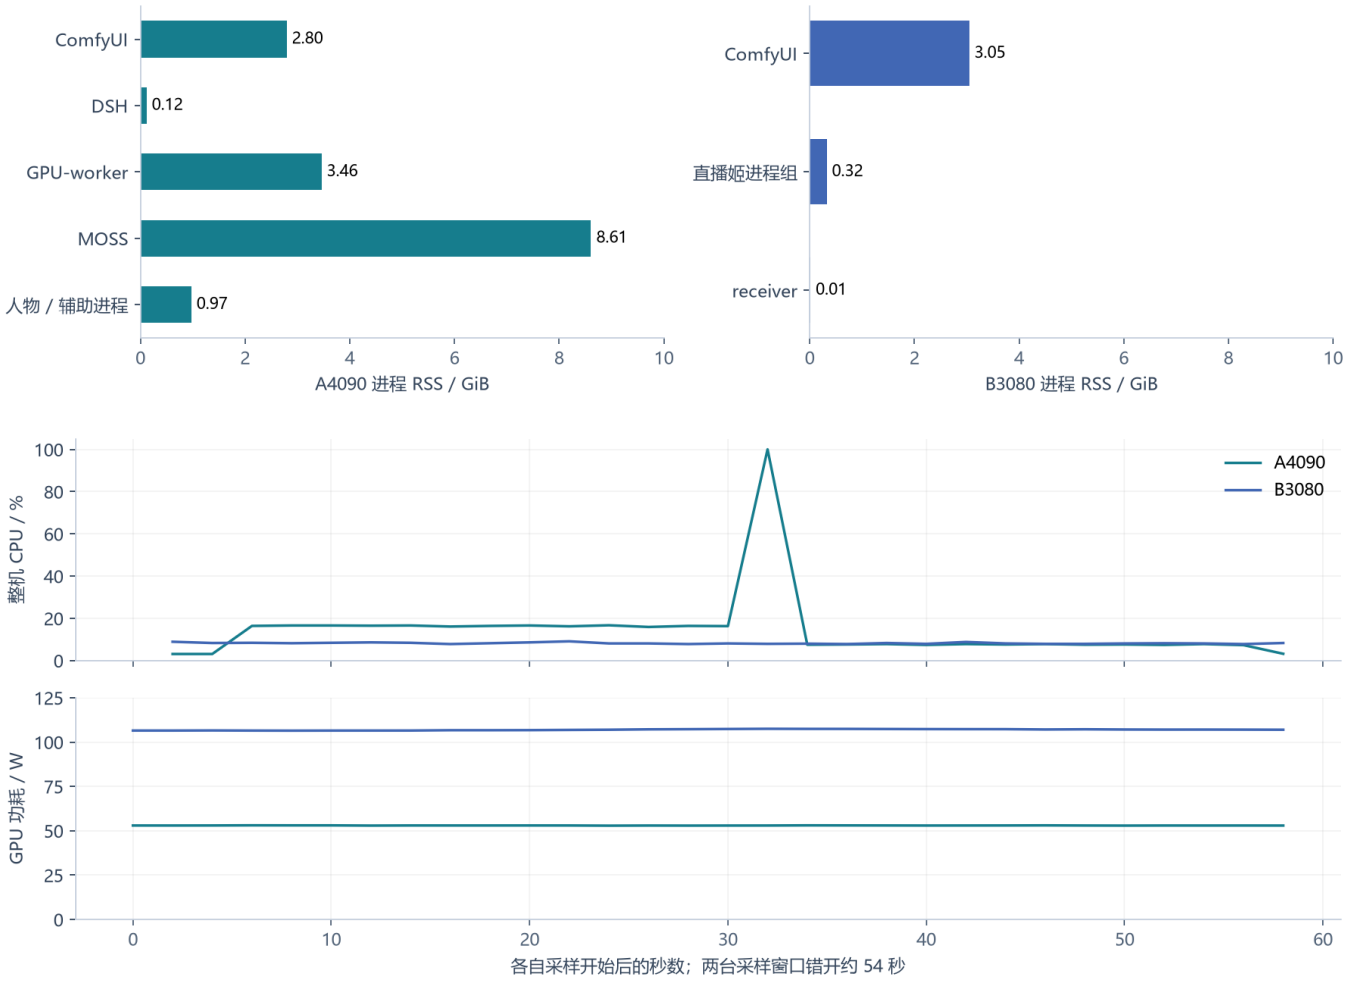
指标	A4090	B3080
整卡显存平均	13,302 MiB / 约 12.99 GiB	1,252.43 MiB / 约 1.22 GiB
整机 RAM 平均	21.25 / 63.90 GiB	11.66 / 63.89 GiB
整机 CPU 均 / 中 / 峰	14.27 / 7.8 / 100 %	8.21 / 8.1 / 9.1 %
GPU 利用率均 / 峰	0.87 / 1 %	4.07 / 5 %
整卡功耗平均	52.97 W	106.96 W
采样本地开始	06:43:17	06:42:23

各 60 秒，30 份 GPU / RAM，29 份有效区间 CPU。A CPU 的 100% 离群点原值保留，原因未归因；两机窗口错开约 54 秒，不能做严格同步因果对比。

MOSS PyTorch allocated 单次峰值约 6,382 - 6,397 MiB；是 TTS 分配器峰值，不是整卡峰值。此前另一段 360 秒 A 验证记录到 GPU 利用率峰值 68%，显存 13,300 MiB，不能冒充本场全程峰值。

旧 B 模型退休前后 9,613 -> 1,223 MiB，释放 8,390 MiB。模型退出显著释放了 B 显存，但当前 4090 的完整语音等待仍受生成路径限制。

常驻进程与采样异常



A MOSS RSS 约 8.61 GiB，GPU worker 3.46 GiB，人物辅助 0.97 GiB，DSH 0.118 GiB；A ComfyUI 另占约 2.80 GiB。B 直播姬进程组约 0.324 GiB、接收器约 0.014 GiB，B ComfyUI 约 3.05 GiB。

RSS 可能包含共享页，不能相加当作独占 RAM。进程 CPU 从单核百分比除以逻辑 CPU 数转换；这里只识别采样开始时的相关进程。ComfyUI 本轮未被调用。

实时调度的所有节拍

机制	当前值	行为
弹幕派发轮询	1,000 ms	有活跃回复或已有排队时不再接入下一条
最小回复启动间隔	8,000 ms	从上次进入队列起计；不是额外固定等待
同观众冷却	15,000 ms	基于当前采集身份；脱敏身份不足以长期识别
平台事件有效期 / 容量	45,000 ms / 50 条	过期标为 EXPIRED；不保证所有弹幕都会回复
DSH 活跃 / 待处理	1 / 4	一房间只允许一个有效发声任务
DSH 排队 TTL / 活跃期限	180 s / 300 s	与平台 45 s TTL 是不同层级
LLM / TTS 超时	90 s / 120 s	超时失败并保留账本，不伪造完成
MOSS 串行服务	1 活跃，至多 4 已登记请求	当前上游单任务，未压测并发吞吐
MOSS 分段 / token	70 字 / 每段最多 800 token	分段全合成后才返回完整 WAV
音频 / 视频节拍	16 kHz 单声道；25 FPS	24 kHz TTS 波形重采样，媒体回执按有效样本确认
A 到 B 音频缓冲	4,000 ms	用约 4 s 启动等待换取抗网络抖动
播放心跳 / 进度回执	1,000 ms / 250 ms	实际有效租约 30 s；恢复时以代次隔离旧音频
下播 drain 上限	30 s	自然结束必须收到连续样本与 natural_end

低流量场景的 dispatch 平均 0.485 秒。8 秒与 15 秒是防连发门槛，并非每个阶段额外叠加的固定等待。平台 TTL 45 秒与 DSH TTL 180 秒属于不同层级；pending 50 不能保证 50 条都被播报。

下播维护与云端调用预算

机制	当前值	行为
维护轮询 / 静默窗口	5 s / 下播后 120 s	开播会打断或延迟后台压缩，不在直播期提交
每日 / 每周维护	03:30 / 周一 04:10	Asia/Taipei；启动补查过去 12 h 的计划点
维护并发 / 单块限制	1 / 200 事件、24 KB、重叠 2 事件	每次运行至多 8 次模型调用，每日 20 次
维护重试 / 租约	最多 5 次；5 s 指数退避至 300 s	模型超时 90 s，租约 120 s，心跳 15 s
预算耗尽 / 渠道不可用	延迟 1 h / 60 s	一小时后只是重查；日额度未重置仍可能继续延迟

本场 A 06:30:03.942 结束，06:32:03.942 满足静默窗口。截止 A 06:51:19，当前任务 DEFERRED / budget，not_before 为本地 07:34:19.928。今日维护已计 20 / 20；一小时后只是重查，日额度未重置仍会继续延迟。

当前保留 10 个维护任务：3 完成、6 失败、1 延后。6 个旧 extraction_failed 达到 5 次尝试；当前 memory_entries=0、summary_versions=6。上下文可对话不等于长期事实压缩已成功。本场没有新增可验证的持久事实。

日期 / 范围	调用	输入token已知	输出token已知	未知usage
2026-10-26 / foreground	9	44365	217	0
2026-10-26 / maintenance	18	124630	4084	0
2026-10-27 / foreground	8	49122	330	0
2026-10-27 / maintenance	20	126196	4032	2

前台上下文与平台中断

案例	LLM / s	输入token	输出token	回复字数
R01	8.75	5669	33	36
R02	10.26	635	22	24
R03	2.22	6357	60	73
R04	12.90	6722	47	58
R05	2.05	7087	54	69
R06	13.26	7454	58	75
R07	4.57	7821	18	19

7 条真实弹幕共 41,745 input / 292 output tokens，均已结算。6000 是上下文估计预算，提供方实际总输入包含提示模板等，单次达到 7,821；缓存细分与价格未采集，不推算费用。

来源时间 / 本地	事件	含义
B 05:10:19	开播 API 成功	随后媒体连接成功
B 05:41:23.308	平台 PREPARING	客户端媒体停止；界面与公开房间状态曾不一致
平台 06:15:13	用户手动重新开播	公开接口恢复 LIVE
A 06:23:11	R07 入账	已完整回复
A 06:30:03.942	内部 ENDED	按用户下播收尾，采集停止，模型常驻

内部会话 83 分 30 秒，包含公开中断，不能称为连续公开直播时长。没有采集到平台终止的具体原因。应增加公共状态对账，不自动重启平台主动终止的直播。

下一步怎么优化

级别 / 项目	依据	下一步验收
P0 / 修复记忆维护失败并保留失败原因	今日 20/20；当前 DEFERRED / budget；旧任务 6 个 extraction_failed	先做结构化返回与来源引用校验，再按失败类别有限重试；清理预算后验证真实持久事实。不应直接加大额度掩盖重复失败
P0 / 公开开播状态对账	05:41:23 平台 PREPARING 后 UI 曾仍显示推流	周期读公开直播状态，并关联直播姬结束事件；发现不一致立即显著提示。不自动重开被平台终止的直播
P1 / 让首句尽快生成并播出	MOSS 全音频 RTF 1.95；TTS 占首播等待约 62.2%	比较保持音色的短句队列与真正流式声码器；保留语音连续性与取消栅栏。目标尚未验证，不能承诺秒回
P1 / 评估本地 codec 的 GPU 路径	当前 CPU codec 平均 4.33 s；A 有显存余量	隔离测试该模型 codec GPU 兼容、音质、总延迟与峰值；完整回归后再替换。能否加速及提升幅度尚未测量
P1 / 根据回复长度控制等待	19 - 75 字对应 10.96 - 32.97 s 完整语音准备	先验证 20 - 40 字首句，加后续补充；不能截断语音或虚报完成。本报告没有修改内容策略
P2 / 自适应接收缓冲	稳定阶段 4 s；长时到达间隔最大 551.5 ms	以 4 s 为基线测试 2 s，再分网络条件对比欠载与首播等待。理论可少约 2 s，不等于已实现
P2 / 统一 trace ID 与采样	MOSS UUID 与 DSH request_id 不同；CPU 有 100% 离群点	贯穿 trace ID、单调时钟阶段打点、每秒 NVML / CPU；区分直播、生成、待机窗口。本次 MOSS 使用经过 32 对匹配校验的分析关联
P2 / 测观众真实端到端延迟与礼物	本次未验证礼物；未测 CDN 观众端音画起点	下一场设置独立观看端，统一时钟标记、音画检测与免费礼物事件留证。当前 34.10 s 仅截止官方客户端播放回执

范围与未测项

1. 主结论以本场 7 条真实 blivedm 弹幕为样本；不是大并发、长周期 SLA。经验 P95 为线性插值描述，7 条样本不能预测稳定尾延迟。

2. 首次播放是官方直播姬嵌入源已接受的正样本回执。它包含回执发送间隔与传输，不能精确定位扬声器物理出声，也不含 B站 CDN 和观众播放器延迟。

3. 主延迟使用 A 设备收到事件与 A 收到回执的同机时钟。平台时间只作参考：曾出现平台到采集器 -212 ms，不能把它解释成负网络耗时。A / B / 平台未做严格时钟同步。

4. 五段官方验收含 4 条 Echo + 1 条云端 Chat，不能用其较低平均值替代全部 AI 对话延迟。测试脚本的轮询耗时与 A 账本起止不同，也不能混用。

5. 历史 20 条保留全部异常：H04 状态 UNKNOWN、只确认了 80,640 / 102,400 样本；H20 从 audio_ready 到正回执 159.913 s。它们来自较早 B 本机调试，不代表当前 B3080 稳定窗口。

6. 资源采样是下播后、模型常驻且预览媒体继续运行的 60 s 窗口。每台 30 条，CPU 第一条弃用后为 29 条；不代表直播 / TTS 峰值。A CPU 仍有 100% 离群点，原值保留，原因未归因。

7. NVIDIA 整卡占用、PyTorch allocated 峰值、进程 RSS、整机已用 RAM 口径不同。RSS 可能含共享页，不能简单相加当作独占物理内存。功耗为整卡瞬时采样，不是电费或训练能耗。

8. 317 次 FPS 为 Canvas 更新计数；不是显示器实际呈现 FPS、MuseTalk 离线吞吐或观众 CDN FPS。零欠载是该采样范围计数，并非未来零卡顿保证。

9. MOSS 关联采用日志先后顺序，再校验全部 32 条回复字数及音频有效样本时长；原适配器没有直接记录同一个 trace ID。当前生成阶段平均值具备这一关联边界。

10. input_tokens / output_tokens 来自渠道返回的 usage。已知计数可以累加；2 次维护 usage 未知，费用、缓存命中、云端排队与首 token 细分未采集。6000 是上下文估计预算，不是提供方实际总输入的硬上限。

11. 本次没有持续记录口型批次耗时、实时 CPU / GPU 全程曲线、显存分进程 NVML 峰值、上行直播编码码率、观众礼物或观众视频录制；缺项按未测列出。

12. 公开报告只含案例编号、时间、长度、用量与状态；不含对话正文、观众昵称、身份哈希、Cookie、推流密钥或渠道密钥。原始私有导出保留在项目 outputs，未提交仓库。

H = 较早调试，C = 当前官方验收，R = 实播

全部案例，含历史异常 (1/2)

案例	本地入账	模式	字数	首回执/s	完成/s	RTF	状态
H01	10-26 17:29:10	echo	38	23.82	32.52	2.18	COMPLETED
H02	10-26 17:29:44	echo	46	22.39	31.58	1.96	COMPLETED
H03	10-26 17:30:20	echo	32	18.01	25.90	2.08	COMPLETED
H04	10-26 17:30:47	echo	26	20.49	-	2.09	UNKNOWN
H05	10-26 17:38:25	echo	38	21.47	34.95	1.88	COMPLETED
H06	10-26 17:39:02	echo	46	24.28	38.92	1.98	COMPLETED
H07	10-26 17:39:47	echo	32	18.28	29.66	2.04	COMPLETED
H08	10-26 17:40:19	echo	26	18.02	28.15	2.10	COMPLETED
H09	10-26 17:40:59	chat	35	24.97	40.15	1.88	COMPLETED
H10	10-26 18:00:36	echo	38	24.19	33.09	2.06	COMPLETED
H11	10-26 18:01:11	echo	46	24.18	33.21	1.97	COMPLETED
H12	10-26 18:01:48	echo	32	18.90	25.59	1.98	COMPLETED
H13	10-26 18:02:15	echo	26	18.89	25.05	2.06	COMPLETED
H14	10-26 18:02:49	chat	34	25.13	33.20	1.92	COMPLETED
H15	10-26 18:30:29	echo	38	23.18	31.95	1.89	COMPLETED
H16	10-26 18:31:02	echo	46	24.14	33.22	1.94	COMPLETED

首回执与完整完成均采用 A 同机时钟；UNKNOWN 的完成时间留空。历史异常未删除或当作零值计入。

H = 较早调试，C = 当前官方验收，R = 实播

全部案例，含历史异常 (2/2)

案例	本地入账	模式	字数	首回执/s	完成/s	RTF	状态
H17	10-26 18:31:40	echo	32	20.11	26.68	2.10	COMPLETED
H18	10-26 18:32:08	echo	26	19.63	25.78	2.11	COMPLETED
H19	10-26 18:32:35	chat	33	44.84	52.20	2.07	COMPLETED
H20	10-26 20:24:13	echo	37	176.55	188.35	2.03	COMPLETED
C01	10-27 04:59:17	echo	43	26.11	37.58	1.79	COMPLETED
C02	10-27 04:59:56	echo	36	23.35	31.48	2.11	COMPLETED
C03	10-27 05:00:31	echo	28	19.34	25.84	2.02	COMPLETED
C04	10-27 05:00:58	echo	26	16.80	21.61	2.23	COMPLETED
C05	10-27 05:01:21	chat	42	28.54	38.92	1.85	COMPLETED
R01	10-27 05:14:38	chat	36	31.02	39.59	1.92	COMPLETED
R02	10-27 05:15:55	chat	24	27.07	31.91	2.16	COMPLETED
R03	10-27 05:18:30	chat	73	37.35	51.70	1.97	COMPLETED
R04	10-27 05:19:29	chat	58	37.82	48.00	1.85	COMPLETED
R05	10-27 05:20:50	chat	69	33.46	47.46	1.78	COMPLETED
R06	10-27 05:23:13	chat	75	51.70	67.48	2.01	COMPLETED
R07	10-27 06:23:11	chat	19	20.32	24.68	2.30	COMPLETED

首回执与完整完成均采用 A 同机时钟；UNKNOWN 的完成时间留空。历史异常未删除或当作零值计入。

数据来源与复现

数据来自 A SQLite 状态账本与平台账本、MOSS 合成日志、B 官方嵌入源指标，以及原生 Windows psutil / nvidia-smi 下播后采样。全部导出是只读事务，不复制正在写入的数据库文件。

运行时代码 fb7e6e8b0f655b9d6b9863486cc0e6f8b1e8f697

报告前文档版本 85d8f25aa1a8c8b66cd95189ce524645b6c0c525

MOSS 分析关联并非原生 trace ID；按日志顺序一一对应，并验证全部 32 条字数与有效音频时长。当前没有微批口型推理耗时曲线，不能编造每帧计算时延。

4090-a-export.json
5d2927507b28afcd4658f20818b804a4e753a2dcb1e7f8470010e418e74e2b50

3080-result.json
77f290e61176d9d94b6c7f96fd2fa487621aaadd743cba4e2be903439a1f0c70

4090-maintenance-export.json
752d40d0d34848a1e86b0ab7b8d4b7b9d262f6b0cfb0b62cc764da1e506bae21

4090-A4090-offair-resources.json
8dc1ba12078e325d0c207f5584571400275db32abdc9bd00885a3f48a67fc9d2

3080-B3080-offair-resources.json
14ae3baef119de1059942240136af08770ede51c25c2c77cc8581cf595fa5fcb

重建：在仓库根执行 python -X utf8 devtools/build-performance-report.py。仅消费 data/evidence.json，不访问模型或直播平台。交互网页、CSV、图表 PNG / SVG 与 Markdown 同目录归档。

本报告完成后，验证浏览器已关闭；仅保留交付报告页。没有新增直播录制，没有修改模型精度、调度政策或公共开播状态。